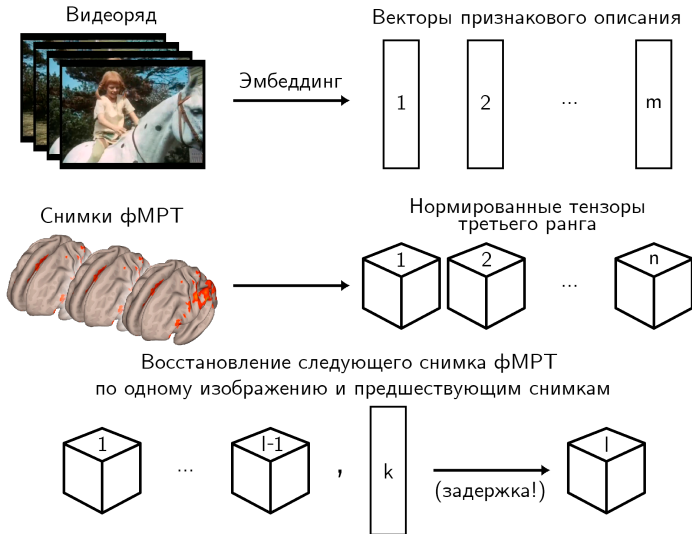


Методы оптимизации линейных задач большой размерности

Дорин Даниил, Киселев Никита

Московский физико-технический институт

12 мая 2023 г.



Пусть \mathcal{P} — видеоряд, ν — частота изображений в видеоряде, t — продолжительность видеоряда:

$$\mathcal{P} = (\mathbf{p}^1, \dots, \mathbf{p}^{\nu \cdot t}), \mathbf{p}^l \in \mathbb{R}^{W_p \times H_p \times C_p}$$

где W_p — ширина изображения, H_p — высота изображения и C_p — число каналов.

\mathcal{S} — последовательность фМРТ снимков некоторого испытуемого, μ — частота снимков фМРТ:

$$\mathcal{S} = (\mathbf{s}^1, \dots, \mathbf{s}^{\mu \cdot t}), \mathbf{s}^l \in \mathbb{R}^{X_s \times Y_s \times Z_s}$$

где X_s , Y_s , Z_s — размерности тензора снимка фМРТ.

Считаем, что известно несколько предыдущих измерений фМРТ \mathcal{S}_0 того же испытуемого. Необходимо построить отображение \mathbf{f} :

$$\mathbf{f}(\mathbf{p}^1, \dots, \mathbf{p}^{k_i - \nu \cdot \Delta t}, \mathcal{S}_0) = \mathbf{s}^i, \mathcal{S}_0 = (\mathbf{s}_0^1, \dots, \mathbf{s}_0^{i-1})$$

которое учитывает задержку Δt .

$$k_i = \frac{\nu \cdot i}{\mu}$$

Предположение марковости: s^i зависит лишь от s^{i-1} и $p^{k_i - \nu \cdot \Delta t}$.

Отображение : $f(p^{k_i - \nu \cdot \Delta t}) = \delta^i$, $i = 2, \dots, L_{\Delta t}$,

$$f = g \circ v,$$

$$v : \mathbb{R}^{W_p \times H_p \times C_p} \rightarrow \mathbb{R}^d, \quad g : \mathbb{R}^d \rightarrow \mathbb{R}^{X_s \times Y_s \times Z_s}.$$

- $L_{\Delta t}$ число пар снимок-изображение из обучающей выборки
- $\delta^i = s^i - s^{i-1}$, $s^k \in \mathbb{R}^{X_s \times Y_s \times Z_s}$
- δ_{ijk} — компонента тензора δ .
- $x = v(p)$, $x = [x_1, \dots, x_d]^T$ — вектор признаков изображения
- $w_{ijk} = [w_1^{ijk}, \dots, w_d^{ijk}]^T$ — вектор весов элемента тензора δ_{ijk}

Для восстановления разности значений в каждом вокселе используется линейная модель

$$g_{ijk}(x, w_{ijk}) = \langle x, w_{ijk} \rangle.$$

Для каждого вокселя в снимке задана обучающая выборка. N — число объектов тренировочной выборки. Функция потерь:

$$\mathcal{L}_{ijk}(w_{ijk}, \Delta t, \alpha) = \frac{1}{2} \sum_{l=2}^{N+1} (g_{ijk}(x^l, w_{ijk}) - \delta_{ijk}^l)^2 + \frac{\alpha}{2} \|w_{ijk}\|_2^2.$$

Требуется минимизировать функцию потерь $\mathcal{L}_{ijk}(\mathbf{w}_{ijk}, \Delta t, \alpha)$ при фиксированных гиперпараметрах Δt и α :

$$\hat{\mathbf{w}}_{ijk} = \arg \min_{\mathbf{w}_{ijk}} \mathcal{L}_{ijk}(\mathbf{w}_{ijk}, \Delta t, \alpha).$$

Определим матрицу объектов тренировочной выборки

$$\mathbf{X} = [\mathbf{x}^2{}^T, \dots, \mathbf{x}^{N+1}{}^T]^T = [\mathbf{x}_j^i] \in \mathbb{R}^{N \times d}$$

и вектор, компонентами которого являются разности значений одного и того же вокселя в снимках тренировочной выборки,

$$\Delta_{ijk} = [\delta_{ijk}^2, \dots, \delta_{ijk}^{N+1}]^T \in \mathbb{R}^N.$$

Тогда решение МНК можно записать в виде:

$$\hat{\mathbf{w}}_{ijk} = (\mathbf{X}^T \mathbf{X} + \alpha \mathbf{I})^{-1} \mathbf{X}^T \Delta_{ijk}.$$

Параметры выборки

- ❶ $L_{\Delta t} = 641 - \mu \cdot \Delta t, \nu = 25 \text{ c}^{-1}, \mu = 1.64 \text{ c}^{-1}$
- ❷ $\mathbf{p} \in \mathbb{R}^{640 \times 480 \times 3}, \mathbf{s} \in \mathbb{R}^{40 \times 64 \times 64}$

При предобработке картинок остаточной CNN так или иначе теряется информация. Целью данной работы является сравнение различных методов решения задач линейной регрессии большой размерности. Предлагается исследовать различные методы ускоренного градиентного спуска, адаптивные методы, покомпонентные методы, SGD и Mini-Batch SGD. В рассматриваемой выборке размерность вектора неизвестных составляет порядка 10^6 .

В качестве функции потерь по-прежнему используем среднеквадратичное отклонение, но уже без регуляризации. В матричном виде задача имеет следующий вид:

$$f(w) = \|Xw - y\|_2^2, \quad X \in \mathbb{R}^{447 \times 921600}$$


$$f(w) \rightarrow \min$$

$$\nabla f(w) = 2X^\top(Xw - y)$$

$$\nabla^2 f(w) = 2X^\top X, \quad X^\top X \in \mathbb{R}^{921600 \times 921600}$$


В дальнейшем считаем, что задача является выпуклой с вырожденной матрицей X , Липшиц-гладкой с некоторой неизвестной константой L , которую не предоставляется возможным посчитать в силу большой размерности матрицы.

$$w_{k+1} = w_k - h \nabla f(w_k)$$



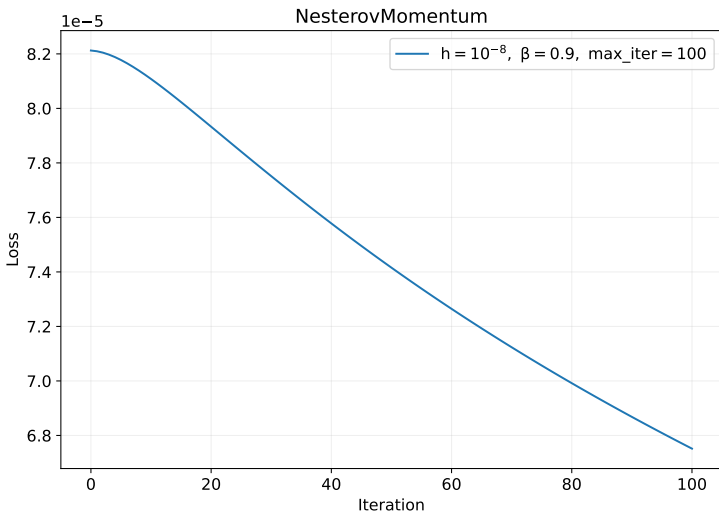
$$v_{k+1} = \beta v_k - h \nabla f(w_k)$$

$$w_{k+1} = w_k + v_{k+1}$$




$$v_{k+1} = \beta v_k - h \nabla f(w_k + \beta v_k)$$

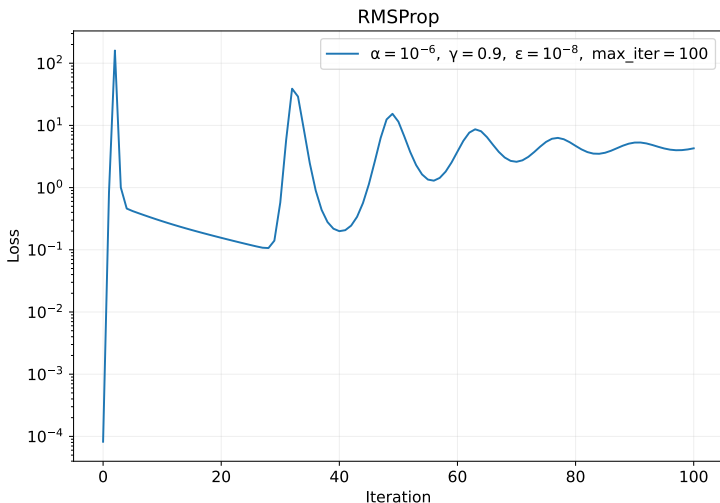
$$w_{k+1} = w_k + v_{k+1}$$




$$G_{k+1} = G_k + [\nabla f(w_k)]^2$$
$$w_{k+1} = w_k - \frac{\alpha}{\sqrt{G_{k+1} + \varepsilon}} \nabla f(w_k)$$



$$G_{k+1} = \gamma G_k + (1 - \gamma)[\nabla f(w_k)]^2$$
$$w_{k+1} = w_k - \frac{\alpha}{\sqrt{G_{k+1} + \varepsilon}} \nabla f(w_k)$$




$$\begin{aligned}v_{k+1} &= \beta_1 v_k + (1 - \beta_1) \nabla f(w_k) \\ G_{k+1} &= \beta_2 G_k + (1 - \beta_2) [\nabla f(w_k)]^2 \\ w_{k+1} &= w_k - \frac{\alpha}{\sqrt{G_{k+1}} + \varepsilon} v_{k+1}\end{aligned}$$



Sample $j_k \in \{1, \dots, 921600\}$

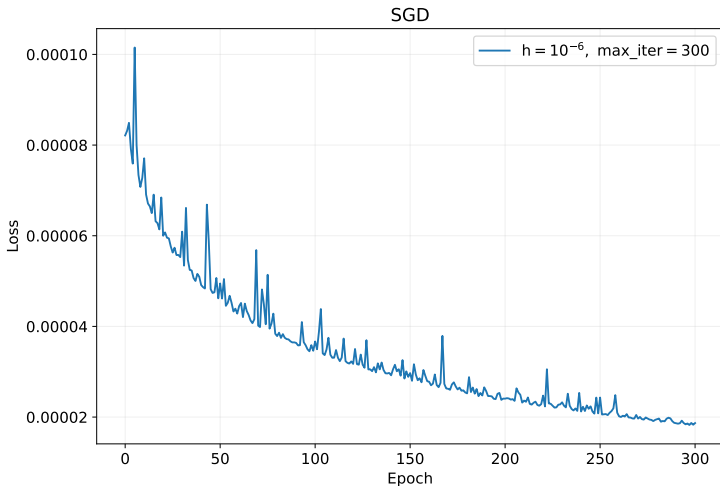
$$g_k = 2X_{j_k}^\top (Xw - y)$$

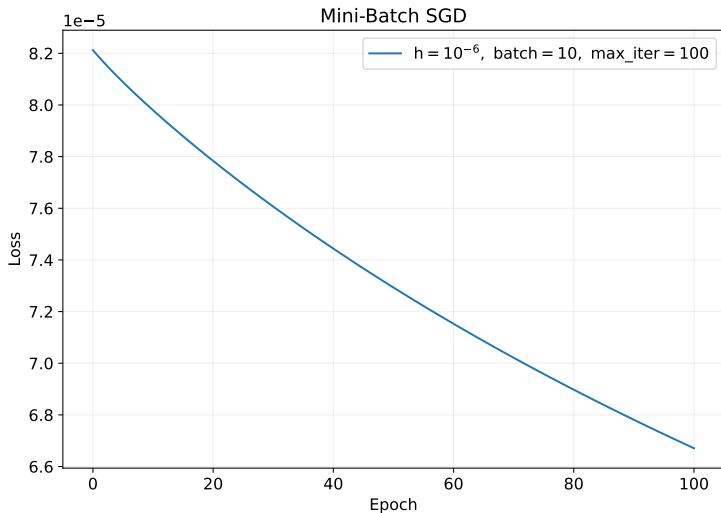
$$w_{j_k}^{k+1} = w_{j_k}^k - hg_k$$

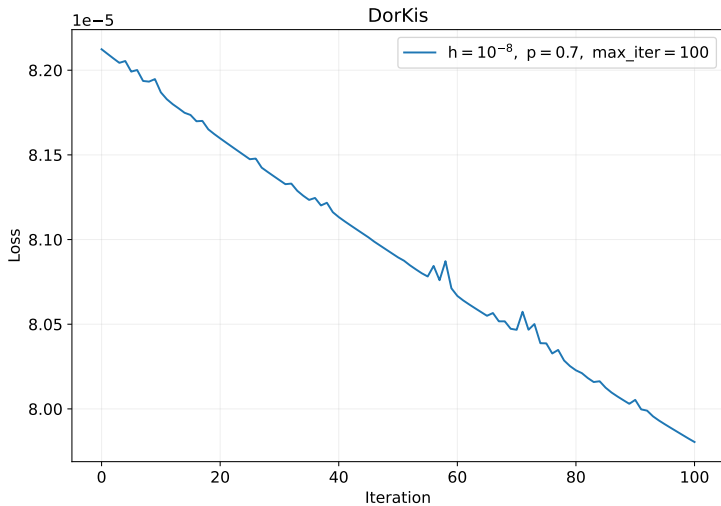


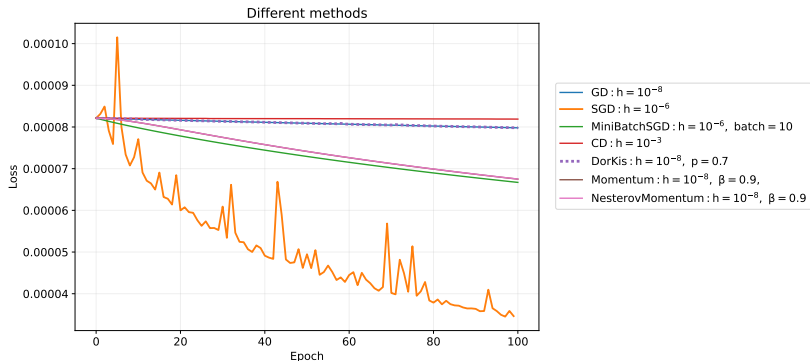
Sample $i_k \in \{1, \dots, 447\}$

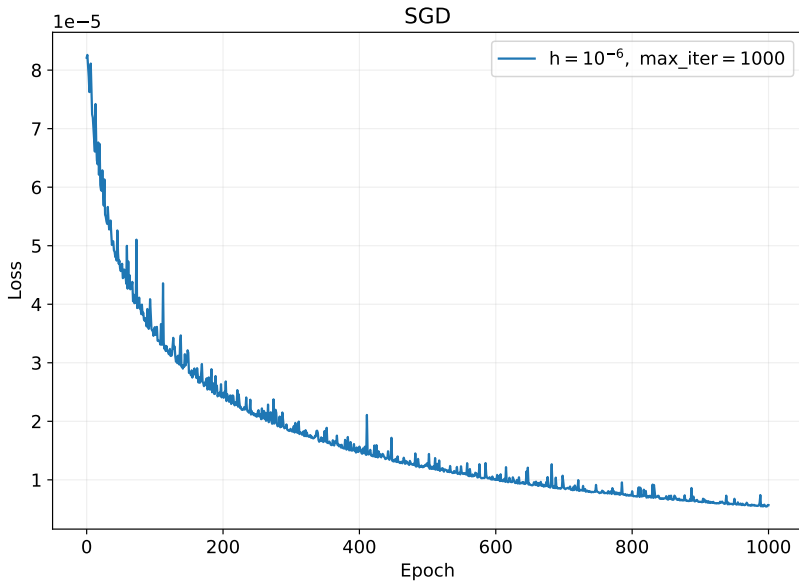
$$w_{k+1} = w_k - h \nabla_{i_k} f(w_k)$$











Спасибо за внимание!

